

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL



02

QUINZENA 1

COMO A IA APRENDE

02

QUINZENA 1

IA NA PRÁTICA ACADÊMICA E PROFISSIONAL

COMO A IA APRENDE

INTRODUÇÃO

Este material aprofunda os conceitos da videoaula do Módulo 2. Você vai entender como sistemas de inteligência artificial (IA) aprendem a partir de dados, o que distingue os três tipos principais de aprendizado de máquina e como a IA evoluiu de sistemas baseados em regras até os modelos de linguagem que você usa hoje. O objetivo é que você consiga, ao fim deste módulo, reconhecer qual tipo de aprendizado está por trás de um sistema que você encontra na prática.



ORIGEM DO MATERIAL

O conteúdo deste *e-book* articula o Módulo 1 do Workshop Fulbright sobre IA na Educação em Engenharia (Katz *et al.*, 2025), facilitado por Mitchell Gerhardt (Virginia Tech), com fontes acadêmicas primárias: *Deep learning* de Ian Goodfellow, Yoshua Bengio e Aaron Courville (2016), *Reinforcement learning* de Richard Sutton e Andrew Barto (2018) e o artigo seminal "*Attention is all you need*" de Vaswani *et al.* (2017).

1. O QUE SIGNIFICA “APRENDER” PARA UMA MÁQUINA

Na computação convencional, um programador escreve regras explícitas: “se o *e-mail* contém a expressão você ganhou um prêmio, mova para *spam*”. Essa abordagem funciona bem para problemas simples e bem definidos, mas tem um limite claro: o programador precisa prever todas as situações possíveis com antecedência, e o mundo real raramente coopera com isso. Filtros de *spam* baseados em regras começaram a falhar assim que *spammers* aprenderam a substituir letras por números e a embaralhar palavras. Não havia como escrever regras rápido o suficiente para acompanhar as variações.

Aprendizado de máquina é uma abordagem diferente. Em vez de escrever regras, o desenvolvedor fornece ao sistema uma quantidade grande de exemplos e permite que o sistema descubra os padrões por conta própria. Arthur Samuel, pesquisador da IBM, cunhou o termo *machine learning* em 1959 ao desenvolver um programa que aprendia a jogar damas e melhorava seu desempenho com a prática, sem ser explicitamente reprogramado para cada situação (Samuel, 1959). A descrição que ele usou permanece válida: dar ao computador a capacidade de aprender sem ser programado explicitamente para cada caso. O que mudou desde então é a escala: décadas de dados, *hardware* especializado e arquiteturas de redes mais profundas tornaram o aprendizado de máquina capaz de resolver problemas que seriam inviáveis por qualquer conjunto de regras escritas manualmente.

2. OS TRÊS TIPOS DE APRENDIZADO DE MÁQUINA

Há três formas principais de organizar o processo de aprendizado, cada uma adequada a tipos diferentes de problema e com características técnicas distintas. A categorização foi consolidada nos anos 1990 e é a base dos capítulos introdutórios dos principais livros-texto da área (Goodfellow; Bengio; Courville, 2016; Mitchell, 1997).

Tipo	Analogia didática	Como funciona	Exemplos documentados
Aprendizado supervisionado	Estudar com gabarito: você vê muitos exercícios resolvidos e aprende o padrão	O modelo recebe pares (entrada, saída correta) rotulados por humanos. O algoritmo ajusta parâmetros para minimizar o erro entre o que prevê e o gabarito (Goodfellow; Bengio; Courville, 2016).	Filtros de <i>spam</i> (e-mails rotulados como <i>spam</i> /não <i>spam</i>); reconhecimento de voz (gravações + transcrições); diagnóstico por imagem (radiografias laudadas por médicos).
Aprendizado não supervisionado	Organizar gaveta de fotos sem legenda: você agrupa por semelhança sem gabarito	O modelo recebe dados sem rótulos e encontra estrutura, agrupamentos ou padrões por conta própria. Não há função de erro explícita baseada em gabarito (Goodfellow; Bengio; Courville, 2016).	Segmentação de clientes por comportamento de compra; detecção de anomalias em transações financeiras; descoberta de tópicos em grandes corpora de texto.
Aprendizado por reforço	Aprender a andar de bicicleta: sem manual, você tenta, cai e ajusta até equilibrar	Um agente recebe recompensas por boas ações e penalidades por erros. Aprende uma política (sequência de ações) que maximiza a recompensa acumulada ao longo do tempo (Sutton; Barto, 2018).	AlphaGo e AlphaZero (DeepMind); controle de refrigeração de <i>data centers</i> do Google; Reinforcement Learning from Human Feedback (RLHF), usado para ajustar LLMs.

UM DETALHE QUE IMPORTA: QUEM ROTULA OS DADOS?

No aprendizado supervisionado, alguém precisa criar os pares (entrada, saída correta) antes que o treinamento comece. Esse trabalho de rotulagem não é automático: é trabalho humano, frequentemente realizado por trabalhadores em plataformas de *crowdwork*, como a Amazon Mechanical Turk, pagos por tarefa e em valores muito baixos. Filtros de *spam* foram treinados por pessoas que marcaram *e-mails*; sistemas de reconhecimento de imagem, por aquelas que identificaram objetos em fotos; modelos de transcrição de voz, pelas que digitaram o que ouviram. Mary Gray e Siddharth Suri documentaram esse trabalho invisível no livro *Ghost work* (2019), que chamaram de “trabalho fantasma”: o esforço humano que sustenta sistemas de IA, mas não aparece na interface final. O Módulo 3 desta quinzena aprofunda esse tema.

Há ainda um tipo de rotulagem que acontece em tempo real: quando você corrige uma previsão automática do teclado, marca um *e-mail* como *spam* ou resolve um

captcha, está produzindo dados rotulados que podem ser usados para treinar ou avaliar sistemas de IA. O uso de dados gerados por usuários para melhorar produtos sem consentimento explícito é um dos pontos de debate ativo na área de ética em IA e está relacionado à regulamentação de privacidade de dados como a Lei Geral de Proteção de Dados (LGPD) brasileira (Lei n. 13.709/2018) e o Regulamento Geral de Proteção de Dados (GDPR) europeu.

3. TRÊS GERAÇÕES DE IA: SIMBÓLICA, CONEXIONISTA E GENERATIVA

Além dos tipos de aprendizado, existe outra forma de classificar sistemas de IA: pela arquitetura interna, ou seja, por como eles representam e processam o conhecimento. Goodfellow, Bengio e Courville (2016) traçam essa história em três eras: a IA simbólica, que dominou o campo até os anos 1980; a IA conexionista, que ressurgiu com o *deep learning* na década de 2010; e a IA generativa, baseada em modelos de linguagem de grande escala, que caracteriza o período atual.

Geração	Como representa o conhecimento	Como aprende	Pontos fortes	Limitações
Simbólica (1956 – 1980s)	Regras explícitas legíveis por humanos: SE condição ENTÃO ação	Conhecimento inserido manualmente por especialistas humanos	Transparente, auditável, explicável	Frágil ante situações não previstas nas regras; não aprende de dados
Conexionista / Deep Learning (1980s – presente)	Pesos numéricos nas conexões entre nós de redes neurais artificiais	Ajuste de pesos via backpropagation: gradiente do erro propaga-se da saída para a entrada	Aprende de dados brutos, generaliza bem, excelente em percepção	Caixa-preta; depende de grandes volumes de dados; pode aprender vieses dos dados
Generativa / LLMs (2017 – presente)	Distribuições de probabilidade sobre tokens (fragmentos de texto)	Pré-treino em corpora massivos + Reinforcement Learning from Human Feedback (RLHF)	Gera texto, código, imagens de alta qualidade; generaliza entre domínios	Não compreende; alucina com fluência; corte de conhecimento na data de treino

IA SIMBÓLICA: O CONHECIMENTO COMO REGRAS LEGÍVEIS

Os primeiros sistemas de IA eram simbólicos. O conhecimento era representado em regras explícitas do tipo SE... ENTÃO..., legíveis por qualquer pessoa treinada na área. O MYCIN, desenvolvido por Edward Shortliffe na Universidade de

Stanford entre 1972 e 1976 (Shortliffe, 1976), diagnosticava infecções sanguíneas usando cerca de 600 regras escritas manualmente por médicos especialistas. A vantagem era a transparência: era possível abrir o sistema, ler cada regra e entender exatamente por que ele chegou à determinada conclusão. A limitação era a fragilidade: qualquer situação não prevista nas regras deixava o sistema perdido, e o processo de escrever regras manualmente era lento e caro.

IA CONEXIONISTA: O CONHECIMENTO NOS PESOS DAS CONEXÕES

A abordagem conexionista, inspirada na neurociência, organiza o processamento em camadas de nós interligados (os neurônios artificiais) com pesos numéricos nas conexões. O *perceptron*, modelo matemático de um neurônio proposto por Frank Rosenblatt em 1958 (Rosenblatt, 1958), foi o ponto de partida. O processo de aprendizado, chamado *backpropagation*, calcula quanto cada peso contribuiu para o erro na saída e o ajusta proporcionalmente: propaga o gradiente do erro de volta pela rede até a entrada. O resultado é que o conhecimento não está em nenhuma regra explícita: está distribuído em milhões de pesos numéricos, o que torna o sistema poderoso, mas também difícil de auditar.

O momento decisivo para o *deep learning* foi a vitória da AlexNet na competição ImageNet em 2012. Alex Krizhevsky, Ilya Sutskever e Geoffrey Hinton (2012) treinaram uma rede neural profunda com 60 milhões de parâmetros em GPUs e alcançaram taxa de erro de 15,3% na classificação de imagens, contra 26,2% do segundo colocado. A margem foi tão grande que mudou o campo: em dois anos, praticamente todos os participantes da competição usavam redes neurais profundas. Geoffrey Hinton recebeu o Prêmio Turing em 2018, junto a Yann LeCun e Yoshua Bengio, pelo conjunto de contribuições ao *deep learning* (ACM, 2019).

IA GENERATIVA: O CONHECIMENTO COMO DISTRIBUIÇÃO DE PROBABILIDADE

Os grandes modelos de linguagem, como o GPT-4 (OpenAI), o Claude (Anthropic) e o Gemini (Google), são sistemas conexionistas treinados com uma tarefa específica: prever qual *token* vem a seguir em uma sequência de texto. Com bilhões de parâmetros e trilhões de *tokens* de treinamento, o modelo aprende implicitamente estruturas linguísticas, fatos do mundo e padrões de raciocínio. A arquitetura que tornou isso viável, o Transformer, foi introduzida por Ashish Vaswani *et al.* (2017). O mecanismo central é a autoatenção, descrita no quadro abaixo:

Conceito	O que é	Exemplo concreto
Token	Fragmento de texto. Pode ser uma palavra inteira, parte de uma palavra ou um sinal de pontuação.	A palavra “naturalização” pode ser dividida em tokens como “natural”, “iza”, “ção” dependendo do vocabulário do modelo.
Embedding (vetor)	Representação numérica de um token em um espaço de alta dimensão. Tokens semanticamente próximos ficam próximos nesse espaço.	No word2vec (Mikolov <i>et al.</i> , 2013): vetor(rei) – vetor(homem) + vetor(mulher) $\approx$ vetor(rainha). A aritmética de vetores captura relações semânticas.
Autoatenção (self-attention)	Mecanismo que calcula, para cada posição na sequência, o peso de atenção que ela deve dar a cada outra posição (Vaswani <i>et al.</i> , 2017).	Na frase “O banco estava cheio de dinheiro”, o modelo precisa decidir se “banco” se refere à instituição financeira ou ao assento. A autoatenção conecta “banco” a “dinheiro” com alto peso.

O PROCESSO DE TREINAMENTO EM TRÊS ETAPAS

Gerhardt (Katz *et al.*, 2025) descreveu o treinamento de LLMs em três fases distintas, cada uma com objetivos e técnicas diferentes. A primeira fase é o pré-treino: o modelo aprende a prever *tokens* mascarados em bilhões de documentos de texto coletados da internet, de livros digitalizados e de código-fonte. Essa fase é extremamente intensiva em energia e computação. A segunda fase é o *fine-tuning* com *datasets* menores e mais controlados, que refinam o comportamento do modelo para que seja mais preciso e fluente em tarefas específicas. A terceira fase é o *Reinforcement Learning from Human Feedback* (RLHF), em que avaliadores humanos classificam pares de respostas do modelo por qualidade e um sistema de aprendizado por reforço ajusta o modelo para gerar respostas parecidas com as preferidas. É o RLHF que produz o comportamento conversacional, seguidor de instruções e aparentemente cuidadoso com segurança que os modelos contemporâneos exibem.

PONTO CRÍTICO

A IA generativa não recupera informação como um mecanismo de busca. Ela gera texto estatisticamente plausível a partir de padrões aprendidos no treinamento. Quando esse texto é correto, é porque padrões corretos dominavam nos dados de treinamento. Quando é incorreto, o modelo não sabe que errou: a alucinação aparece com a mesma fluência e o mesmo tom assertivo que o conteúdo preciso. Esse fenômeno é estrutural, não um *bug* a ser corrigido. Trata-se de uma consequência direta de como esses modelos são treinados e entendê-lo é o que permite usar LLMs com critério.

4. O QUE MUDA NA SUA PRÁTICA

Saber como a IA aprende muda a forma como você interpreta o que ela produz. Quando um modelo de linguagem responde com confiança a uma pergunta sobre um evento recente, lembre-se que ele foi treinado com dados até determinada data, o chamado “corte de conhecimento”, sem acesso a informações posteriores. Quando ele cita uma referência bibliográfica, lembre-se que ele não recuperou esse artigo de uma biblioteca: ele gerou uma referência plausível, que pode ou não existir. Quando ele diz que “segundo estudos recentes”, essa afirmação não tem mais garantia de precisão do que qualquer outra parte da resposta. Verificar fontes citadas por LLMs antes de usá-las é prática necessária, não opcional: as atividades desta quinzena são desenhadas para desenvolver exatamente essa postura.

REFERÊNCIAS

As obras abaixo são verificáveis e acessíveis nas plataformas indicadas.

ASSOCIATION FOR COMPUTING MACHINERY [ACM]. Fathers of the deep learning revolution receive ACM A.M. Turing Award. **ACM**, 2019. Disponível em: <https://awards.acm.org/about/2018-turing>. Acesso em: 29 maio 2026.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. Cambridge: MIT Press, 2016. *E-book*. Disponível em: <https://www.deeplearningbook.org>. Acesso em: 29 maio 2026.

GRAY, M.; SURI, S. **Ghost work**: how to stop Silicon Valley from building a new global underclass. New York: Houghton Mifflin Harcourt, 2019.

KATZ, B. *et al.* Integrating artificial intelligence into engineering education. *In*: WORKSHOP FULLBRIGHT., 2025, São Paulo. **Anais [...]**, São Paulo: Centro de Inovação da USP, 2025. Módulo 1: Gerhardt, M. Introduction to Generative AI.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. **Advances in Neural Information Processing Systems**, [S. l.: s. n.], v. 25, 2012.

MIKOLOV, T. *et al.* Efficient estimation of word representations in vector space. **arXiv**, [S. l.: s. n.], 2013. Disponível em: <https://arxiv.org/pdf/1301.3781>. Acesso em: 29 maio 2026.

MITCHELL, T. M. **Machine learning**. New York: McGraw-Hill, 1997.

ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological Review**, [S. l.: s. n.], v. 65, n. 6, p. 386-408, 1958.

SAMUEL, A. L. Some studies in machine learning using the game of checkers. **IBM Journal of Research and Development**, [S. l.: s. n.], v. 3, n. 3, p. 210-229, 1959.

SHORTLIFFE, E. H. **Computer-based medical consultations: MYCIN**. New York: Elsevier, 1976.

SUTTON, R. S.; BARTO, A. G. **Reinforcement learning: an introduction**. 2. ed. Cambridge: MIT Press, 2018. *E-book*. Disponível em: <http://incompleteideas.net/book/the-book.html>. Acesso em: 29 maio 2026.

VASWANI, A. *et al.* Attention is all you need. **Advances in Neural Information Processing Systems**, [S. l.: s. n.], v. 30, 2017. Disponível em: <https://arxiv.org/pdf/1706.03762>. Acesso em: 29 maio 2026.

CRÉDITOS

Autor Principal: **Prof. Dr. José Avelino Placca**
Coordenação: **Wesley de Souza Lima**
Design Instrucional: **Claudia Mori**
Revisão Textual: **Juliana Nascimento Costa e Valteir Vaz**
Edição de Arte: **Henrique Inhauser Caldas**

Título da obra:
Como a IA aprende

Local de publicação:
São Paulo, Brasil

Instituição: **Univesp**
Ano de publicação: **2026**
Número de páginas: **12 p.**
Palavras-chave: **1. Inteligência Artificial. 2. Aprendizado de Máquina. 3. IA Generativa**



ATRIBUIÇÃO – NÃO COMERCIAL (BY - NC - ND)

PROIBIDA A EDIÇÃO. PROIBIDO USO COMERCIAL. PERMITE SOMENTE REDISTRIBUIÇÃO. PERMITE O DOWNLOAD E COMPARTILHAMENTO, CONTANTO QUE O AUTOR SEJA MENCIONADO E A OBRA INALTERADA.